

รายงานฉบับสมบูรณ์ (ปิดโครงการวิจัย)

ชื่อโครงการ

อุปกรณ์ตรวจสอบโซ่ด้วยเทคโนโลยีคอมพิวเตอร์วิทัศน์และการเรียนรู้เชิงลึก (Chain Inspection Device using Computer Vision and Deep Learning Technology)

หัวข้อ	รายละเอียด
ผู้วิจัย	นายศิวกร สุขประเสริฐชัย และคณะ
หน่วยงาน	คณะพาณิชยศาสตร์บริหารธุรกิจ มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา ชลบุรี 20230
แหล่งทุน	ทุนอุดหนุนวิจัยและนวัตกรรม ตามยุทธศาสตร์ มก. วิทยาเขตศรีราชา ประจำปีงบประมาณ 2568
งบประมาณ	292,500 บาท
ระยะเวลา	1 ปี (16 ธ.ค. 2567 – 15 ธ.ค. 2568)

บทคัดย่อ

โซ่รับแรง เช่น โซ่สมอเรือ (anchor chain) และโซ่ผูกยึด (mooring chain) เป็นชิ้นส่วนวิกฤต ด้านความปลอดภัยที่ต้องได้รับการตรวจสอบสภาพการสึกกร่อน (wear) และการกัดกร่อน (corrosion) อย่างสม่ำเสมอตามข้อกำหนดของสมาคมการจัดชั้นเรือสากล (International Association of Classification Societies, IACS) ซึ่งกำหนดเกณฑ์การปลดระวางเมื่อขนาดเส้นผ่านศูนย์กลางเฉลี่ยที่ตำแหน่งสึกกร่อน ลดลงเกิน 12% ของขนาดดั้งเดิม การตรวจสอบในปัจจุบันยังพึ่งพาแรงงานคนและเครื่องมือวัดสัมผัส (เวอร์เนียคาลิเปอร์) เป็นหลัก ทำให้สิ้นเปลืองเวลาและไม่มีความสม่ำเสมอระหว่างผู้ตรวจ

โครงการนี้พัฒนานต้นแบบระบบตรวจสอบโซ่อัตโนมัติบนบก (on-shore) โดยผสานเทคโนโลยี คอมพิวเตอร์วิทัศน์ (Computer Vision) และการเรียนรู้เชิงลึก (Deep Learning) บนชุดประมวลผล ขอบ (edge computing) NVIDIA Jetson การดำเนินงานแบ่งเป็นสองแนวทาง แนวทางแรกใช้ โครงข่ายตรวจจับวัตถุ YOLOv8 ตรวจจบบริเวณกัดกร่อนเชิงคุณภาพ ($mAP@50 = 63.9\%$) และแนวทางที่สอง ซึ่งเป็นผลลัพธ์หลักของโครงการ คือการวัดการสึกกร่อนเชิงเรขาคณิต (geometry-based wear measurement) ด้วยกระบวนการ 8 ขั้นตอน ตั้งแต่การแบ่งส่วนภาพด้วย FastSAM การแก้เพอร์สเปกทีฟ การสร้างแบบจำลอง ข้อโซ่แนวตั้งด้วยจุดควบคุม 12 จุด (พื้นที่ A) การสร้างแบบจำลองวงกลมลดทอน (พื้นที่ B) และการวัด การสึกกร่อนจากอัตราส่วนพื้นที่ซ้อนทับ $Wear = area(A \cap B) / area(A)$ พร้อมการชดเชย พารัลแลกซ์ (parallax normalization)

ผลการทดสอบกับตัวอย่างโซ่ 3 ระดับการสึกกร่อน ให้ลำดับการสึกกร่อนที่ถูกต้องตรงตามกายภาพ (ใหม่ $18.8\% < 24.3\% < 31.9\%$) สอดคล้องกับค่าอ้างอิงจากเวอร์เนียคาลิเปอร์ (ใหม่ $< 30\% < 50\%$) และการชดเชยพารัลแลกซ์ลดการกระจายของค่าภายในเฟรมเดียวจาก ~ 10 จุดเปอร์เซ็นต์เหลือ ~ 1.5 จุดเปอร์เซ็นต์ ผลงานนี้แสดงให้เห็นความเป็นไปได้ของการตรวจวัดการสึกกร่อนเชิงปริมาณด้วยภาพเดียว (monocular) และวางรากฐานสำหรับการต่อยอดสู่ระบบอัตโนมัติ และการรายงานผลตามนิยาม IACS โดยตรงในระยะต่อไป

คำสำคัญ: การตรวจสอบโซ่, การสึกกร่อน, คอมพิวเตอร์วิทัศน์, การเรียนรู้เชิงลึก, การแบ่งส่วนภาพ, IACS, YOLOv8, FastSAM

Abstract

Load-bearing chains such as anchor chains and mooring chains are safety-critical components that must be regularly inspected for wear and corrosion in accordance with the requirements of the International Association of Classification Societies (IACS), which mandates replacement once the mean diameter at the worn section drops more than 12% below the original gauge. Current inspection still relies mainly on manual labour and contact gauges (vernier calipers), which is time-consuming and inconsistent between inspectors.

This project develops an on-shore automated chain-inspection prototype that combines Computer Vision and Deep Learning on an NVIDIA Jetson edge-computing module. Two approaches were pursued. The first uses the YOLOv8 object detector for qualitative corrosion detection (mAP@50 = 63.9%). The second — the project's principal result — is a geometry-based wear measurement realised through an 8-stage pipeline: FastSAM segmentation, perspective correction, a 12-control-point vertical-link model (area A), a horizontal-wire circle model (area B), and a wear metric defined as the overlap ratio $\text{Wear} = \text{area}(A \cap B) / \text{area}(A)$, together with a parallax-normalization step.

On three chain samples spanning different wear states, the method produced a physically correct wear ordering (new 18.8% < 24.3% < 31.9%), consistent with the caliper ground truth (new < 30% < 50%), while parallax normalization reduced within-frame scatter from ~10 to ~1.5 percentage points. The work demonstrates the feasibility of quantitative monocular wear measurement and lays the groundwork for a future stereo-vision extension reporting directly against the IACS criterion.

Keywords: chain inspection, wear, computer vision, deep learning, image segmentation, IACS, YOLOv8, FastSAM

สารบัญ (โครงเรื่อง)

- บทที่ 1 บทนำ — หลักการและเหตุผล วัตถุประสงค์ ขอบเขต ประโยชน์ที่คาดว่าจะได้รับ
- บทที่ 2 การทบทวนวรรณกรรมและทฤษฎีที่เกี่ยวข้อง — มาตรฐาน IACS, NDT/MFL, การประมวลผลภาพ, การเรียนรู้เชิงลึก, foundation models, การวัดด้วยภาพ, เรขาคณิตหลายมุมมอง
- บทที่ 3 วิธีการดำเนินงานวิจัย — ฮาร์ดแวร์ แนวทาง YOLOv8 การ pivot และกระบวนการวัด 8 ขั้นตอน
- บทที่ 4 ผลการทดลองและการอภิปราย — ผล YOLO, การแบ่งส่วน, ผลการวัดต่อขั้นตอน, การชดเชยพารัลแลกซ์, การเปรียบเทียบกับค่าจริง, ข้อจำกัด
- บทที่ 5 สรุปผล ข้อเสนอแนะ และแผนระยะต่อไป
- เอกสารอ้างอิง และ ภาคผนวก

บทที่ 1 บทนำ


1.1 หลักการและเหตุผล

โซ่ (chain) เป็นชิ้นส่วนรับแรงดึงที่ใช้อย่างแพร่หลายในงานทางทะเลและพาณิชย์ โดยเฉพาะ โซ่สมอเรือ (anchor chain) และ โซ่ผูกยึดทุ่น/แท่น (mooring chain) ซึ่งต้องรับภาระแบบพลวัต (dynamic loading) ตลอดอายุการใช้งาน ประกอบกับการสัมผัสพื้นทะเล การกัดกร่อนจากน้ำทะเล และการเสียดสีระหว่างข้อโซ่ ทำให้เกิดการสึกกร่อนสะสมที่ตำแหน่งสัมผัส (interlock) ระหว่างข้อโซ่ สองข้อที่คล้องกัน หากการสึกกร่อนลุกลามจนขนาดหน้าตัดลดลงมากเกินไปความสามารถในการรับแรง จะลดลงอย่างมีนัยสำคัญและอาจนำไปสู่การขาดของโซ่ ซึ่งเป็นอุบัติเหตุร้ายแรงต่อชีวิตและทรัพย์สิน

องค์กรจัดชั้นเรือภายใต้ สมาคมการจัดชั้นเรือสากล (International Association of Classification Societies, IACS) จึงกำหนดข้อบังคับให้ตรวจสอบโซ่สมอและอุปกรณ์ผูกยึดเป็นระยะ (annual survey และ special periodical survey ทุก 5 ปี) โดยหนึ่งในเกณฑ์เชิงปริมาณที่สำคัญคือ การวัดขนาด เส้นผ่านศูนย์กลางของข้อโซ่ที่ตำแหน่งสีกกร่อน เทียบกับขนาดดั้งเดิม [1], [2] ตามหลักการ

$$\bar{D} = \frac{d_1 + d_2}{2}, \quad \bar{D} \geq 0.88 D_0$$

เมื่อ D_0 คือขนาดเส้นผ่านศูนย์กลางดั้งเดิมของโซ่ และ d_1, d_2 คือขนาดที่วัดได้ในสองแนวตั้งฉาก ณ ตำแหน่งสีกกร่อน กล่าวคือ หากการสีกกร่อนเกิน 12% ของขนาดดั้งเดิม โซ่ต้องถูกปลดระวาง รูปที่ 1.1 แสดงหลักการของเกณฑ์นี้



รูปที่ 1.1 เกณฑ์การสีกกร่อนของ IACS: โซ่ต้องถูกปลดระวางเมื่อ $\bar{D} < 0.88 D_0$ (สีกกร่อนเกิน 12%) [1], [2] (จัดทำโดย คณะผู้วิจัย)

ในทางปฏิบัติ การตรวจสอบเบื้องต้น (initial/close-up survey) ยังคงพึ่งพาแรงงานคนในการมองด้วยตา (visual inspection) และวัดขนาดด้วยเครื่องมือสัมผัส เช่น เวอร์เนียร์คาลิเปอร์ หรือแหวนวัด (go/no-go gauge) ที่ละข้อ วิธีนี้มีข้อจำกัดสำคัญคือ (ก) ใช้เวลาและกำลังคนสูงเนื่องจากโซ่สมอมีความยาวหลาย ร้อยเมตรและต้องคลี่วางเรียง (ranging) ทั้งเส้น (ข) ผลการประเมินขึ้นกับประสบการณ์และความล้าของ ผู้ตรวจ ทำให้เกิดความไม่สม่ำเสมอ (inter-inspector variability) และ (ค) การเข้าถึงตำแหน่งสัมผัสที่สีก จริงทำได้ยากเพราะถูกข้อโซ่ที่คล้องกันบดบัง

ด้วยความก้าวหน้าของ คอมพิวเตอร์วิทัศน์ (Computer Vision) และ การเรียนรู้เชิงลึก (Deep Learning) ในทศวรรษที่ผ่านมา งานตรวจสอบสภาพโครงสร้างโลหะเชิงอัตโนมัติได้รับความนิยมอย่างมาก ทั้งการตรวจจับการกัดกร่อนบน สะพานเหล็ก เสาส่งไฟฟ้า และโครงสร้างไฮดรอลิก [9], [10], [12], [22] ตลอดจนการตรวจสอบลวดสลิง (wire rope) ด้วยการรวมสัญญาณสนามแม่เหล็กไว้กับภาพ [13], [14], [15] โครงการนี้จึงมุ่งพัฒนาด้านแบบระบบตรวจสอบโซ่อัตโนมัติที่ประมวลผลบนชุด edge computing (NVIDIA Jetson) [21] เพื่อลดการพึ่งพาแรงงานคน เพิ่มความสม่ำเสมอ และวางรากฐานสู่การตรวจสอบเชิงปริมาณ ที่ทวนสอบย้อนกลับได้

1.2 ปัญหาการวิจัยและช่องว่างขององค์ความรู้

งานตรวจจับการกัดกร่อนด้วยการเรียนรู้เชิงลึกส่วนใหญ่ให้ผลลัพธ์ **เชิงคุณภาพ** (มี/ไม่มีการกัดกร่อน หรือรอบขอบเขต/ มาสก์ของบริเวณสนิม) [9], [11], [12] ซึ่งแม้จะมีประโยชน์ในการคัดกรอง แต่ยังไม่สามารถให้ค่าปริมาณการสีกกร่อนเป็นเปอร์เซ็นต์ ที่นำไปเทียบกับเกณฑ์เชิงมิติ (dimensional) ของ IACS ได้โดยตรง นอกจากนี้ "สนิม/การกัดกร่อนที่ผิว" (surface corrosion) กับ "การสีกหรือที่ทำให้ขนาด ลดลง" (dimensional wear) เป็นคนละปรากฏการณ์ทางวิศวกรรม โดย

เกณฑ์ความปลอดภัยของ IACS อ้างอิงกับ *ขนาดที่หายไป/ไม่ใช่ว่าพื้นที่* สนิมบนผิว ช่องว่างขององค์ความรู้จึงอยู่ที่ **การวัด การสึกกร่อน เชิงมิติจากภาพให้เป็นค่าปริมาณที่สอดคล้องกับมาตรฐาน**

1.3 วัตถุประสงค์ของโครงการ

1. ออกแบบและพัฒนาระบบตรวจจับการกัดกร่อน (สนิม/รอยร้าว) ด้วย Deep Learning
2. ออกแบบและพัฒนาระบบวัดการสึกกร่อนด้วย Computer Vision
3. ลดจำนวนคนและเวลาในการตรวจสอบโซ่เบื้องต้น
4. เผยแพร่ผลงานวิจัยในวารสารวิชาการระดับชาติ/นานาชาติ
5. นวัตกรรมเทคโนโลยีดิจิทัลและปัญญาประดิษฐ์กับอุตสาหกรรมทางทะเลและพาณิชย์นาวี

หมายเหตุเชิงนโยบายของโครงการ: ในระหว่างการทำงาน คณะผู้วิจัยได้ **ปรับจุดเน้น (pivot)** จาก วัตถุประสงค์ข้อ 1 (การตรวจจับการกัดกร่อนเชิงคุณภาพ) ไปสู่วัตถุประสงค์ข้อ 2 (**การวัดการสึกกร่อนเชิงกายภาพ/เชิงปริมาณ**) เป็นผลลัพธ์หลักของโครงการ ด้วยเหตุผลที่อธิบายไว้ใน หัวข้อ 3.4 เนื่องจากการวัดการสึกกร่อนเป็นตัวชี้วัดเชิงปริมาณที่สอดคล้องกับเกณฑ์ IACS 12% โดยตรง และเป็นข้อมูลที่ใช้ตัดสินใจ (go/no-go) ได้จริง

1.4 ขอบเขตของการวิจัย

- ตัวอย่างทดสอบเป็น **โซ่แบบไม่มีสตั๊ด (open-link/stud-less)** ขนาด 10×25 มม. จำนวน 3 ระดับการ สึกกร่อน (ใหม่, ~30%, ~50%) ถ่ายภาพในสภาพห้องปฏิบัติการ
- ระบบทำงานแบบ **ภาพเดี่ยว (monocular)** มุมมองด้านบน โดยออกแบบฮาร์ดแวร์รองรับการต่อยอด สู่สแตนด์โอเวอร์
- การประเมินความถูกต้องใช้ค่าอ้างอิงจาก **เวอร์เนียร์คาลิเปอร์** เป็น ground truth
- ขอบเขต **ไม่รวม** การตรวจสอบใต้น้ำ (subsea) และการทดสอบภาระเชิงกล (proof load test)

1.5 ประโยชน์ที่คาดว่าจะได้รับ

1. ต้นแบบระบบตรวจวัดการสึกกร่อนของโซ่เชิงปริมาณที่ทดสอบได้ ลดการพึ่งพาแรงงานคน
2. องค์ความรู้ด้านการวัดเชิงมิติด้วยภาพ (vision-based metrology) สำหรับชิ้นส่วนที่มีการบิดบังกันเอง
3. ฐานข้อมูลฮาร์ดแวร์/ซอฟต์แวร์สำหรับต่อยอดสู่ระบบตรวจสอบแบบเวลาจริงบนสายการผลิต/สายตรวจสอบ
4. การบูรณาการปัญญาประดิษฐ์กับอุตสาหกรรมพาณิชย์นาวีของประเทศ

บทที่ 2 การทบทวนวรรณกรรมและทฤษฎีที่เกี่ยวข้อง

บทนี้ทบทวนงานวิจัยและทฤษฎีพื้นฐานใน 7 กลุ่มที่เกี่ยวข้องกับระบบที่พัฒนา ได้แก่ (2.1) มาตรฐานและ เกณฑ์การตรวจสอบโซ่, (2.2) การตรวจสอบแบบไม่ทำลายของโซ่/ลวดสลิง, (2.3) การประมวลผลภาพ เชิงเรขาคณิตพื้นฐาน, (2.4) การเรียนรู้เชิงลึกและการตรวจจับวัตถุ, (2.5) แบบจำลองพื้นฐานสำหรับการ แบ่งส่วนภาพ, (2.6) การวัดขนาดเชิงมิติด้วยภาพ, และ (2.7) เรขาคณิตหลายมุมมองและพารัลแลกซ์

2.1 มาตรฐานและเกณฑ์การตรวจสอบโซ่ (IACS)

IACS เป็นองค์ความรู้ร่วมมือของสมาคมจัดชั้นเรือชั้นนำของโลก ทำหน้าที่กำหนดข้อบังคับเชิงเทคนิค (Unified Requirements, UR) และขอแนะนำ (Recommendations, Rec.) สำหรับการต่อเรือและการ ตรวจสอบเรือ ในส่วนที่เกี่ยวข้อง อุปกรณ์สมอและการผูกยึด เอกสาร **IACS Rec. No. 10 — Anchoring, Mooring and Towing Equipment** [1] และ **UR A1/A2** [2] ระบุขั้นตอนการตรวจสอบ ได้แก่ การวัด ขนาดข้อโซ่ การตรวจการบิดเบี้ยว/รอยร้าว การประเมินการกัดกร่อนแบบรุกราน (pitting) และสภาพสตั๊ด (stud) เกณฑ์เชิงมิติที่ใช้กันทั่วไปคือ **การยอมรับ/ปฏิเสธโซ่จากอัตราการสูญเสีย**

เส้นผ่านศูนย์กลาง โดยค่าที่ใช้อ้างอิงบ่อยคือ **12% ของขนาดดั้งเดิม** (สอดคล้องกับแนวทางการพิจารณาเปลี่ยนหมด/พิน เมื่อสึกถึง 12% ของเส้นผ่านศูนย์กลาง) [1]

ประเด็นสำคัญคือ เกณฑ์นี้เป็น **เกณฑ์เชิงมิติ (dimensional)** ไม่ใช่เชิงพื้นที่ผิว การออกแบบระบบวัด จึงต้องให้ผลลัพธ์เป็น **ขนาด/สัดส่วนที่หายไป** เพื่อให้เทียบกับมาตรฐานได้โดยตรง — เป็นเหตุผลหลักที่ โครงการปรับแนวทางไปสู่การวัดเชิงเรขาคณิต (บทที่ 3)

2.2 การตรวจสอบแบบไม่ทำลายของโซ่และลวดสลิง (NDT)

การตรวจสอบชิ้นส่วนโลหะรับแรงแบบไม่ทำลาย (Non-Destructive Testing, NDT) มีหลายเทคนิค สำหรับลวดสลิงและสายเคเบิลเหล็ก เทคนิคที่ใช้แพร่หลายที่สุดคือ **การรั่วไหลของสนามแม่เหล็ก (Magnetic Flux Leakage, MFL)** ซึ่งตรวจจับความผิดปกติเฉพาะที่ (local flaw เช่น ลวดขาด) และ การสูญเสียหน้าตัดโลหะ (loss of metallic cross-sectional area) ในโครงสร้างเฟอร์โรแมกเนติก [13], [15] งานวิจัยล่าสุดผสาน MFL กับการประมวลผลภาพและการเรียนรู้เชิงลึก เช่น การแปลงสัญญาณ MFL เป็น ภาพแล้วใช้โครงข่าย YOLOv9 ตรวจจับตำแหน่งข้อบกพร่อง [14] หรือใช้ 1D-CNN วิเคราะห์สัญญาณ MFL โดยตรง [15] และการหลอมรวมข้อมูล MFL กับข้อมูลแสงที่มองเห็นได้ (visible light) เพื่อจำแนกลวดขาดเชิงปริมาณ [13]

ข้อจำกัดของ MFL คือ ต้องอาศัยหัวตรวจสัมผัส/ใกล้ชิ้นงานและแม่เหล็กกำลังสูง เหมาะกับลวดสลิงที่ เคลื่อนผ่านหัวตรวจ แต่ไม่สะดวกสำหรับการวัด **ขนาดทางเรขาคณิต** ของข้อโซ่ขนาดใหญ่ที่ต้องการ ประเมินสัดส่วนการสึกกร่อนตามเกณฑ์ IACS งานตรวจสอบด้วยภาพ (vision-based) จึงเป็นแนวทางเสริม ที่ให้ข้อมูลเชิงมิติได้โดยตรงและไม่ต้องสัมผัสชิ้นงาน

2.3 การประมวลผลภาพเชิงเรขาคณิตพื้นฐาน

ระบบที่พัฒนาใช้เครื่องมือประมวลผลภาพคลาสสิกหลายชนิดในการสกัดขอบและรูปทรงจากมาสก์ การแบ่งส่วน โดยอ้างอิงทฤษฎีมาตรฐานด้านการประมวลผลภาพดิจิทัล [18]

- **การกำหนดขีดแบ่ง (Thresholding):** การแปลงภาพระดับเทาเป็นภาพไบนารีด้วยขีดแบ่ง วิธีอัตโนมัติ ที่ใช้อ้างอิงคือวิธีของ Otsu ซึ่งเลือกขีดแบ่งที่ทำให้ความแปรปรวนระหว่างคลาสสูงสุด [19]
- **การติดป้ายองค์ประกอบเชื่อมต่อ (Connected-Component Labelling):** ใช้แยกวัตถุ (blob) ออกจาก กันเพื่อคัดเลือกข้อโซ่/ลวดที่สนใจและกำจัดสัญญาณรบกวนขนาดเล็ก [18]
- **การหาเส้นขอบและพื้นที่ (Contour & Area):** ใช้อัลกอริทึมติดตามขอบของ Suzuki–Abe [20] (มีในไลบรารี OpenCV) ในการดึงรูปหลายเหลี่ยมปิด และคำนวณพื้นที่ด้วย **สูตร Shoelace (Gauss's area formula)** ซึ่งให้พื้นที่ของรูปหลายเหลี่ยมจากพิกัดจุดยอด เป็นหัวใจของการหาพื้นที่ A , B และ $A \cap B$


สูตร Shoelace สำหรับรูปหลายเหลี่ยมที่มีจุดยอด (x_i, y_i) :

$$\text{Area} = \frac{1}{2} \left| \sum_{i=1}^n (x_i y_{i+1} - x_{i+1} y_i) \right|$$

- **เส้นโค้งเบซิเยร์ (Bézier curves):** ใช้สร้างส่วนโค้งปลายข้อโซ่ที่ถูกบดบัง (occluded cap) ขึ้นใหม่ จากจุดควบคุมเส้นโค้งเบซิเยร์กำลังสอง (quadratic) นิยามด้วยจุดควบคุมสามจุด P_0, P_1, P_2 :

$$C(t) = (1 - t)^2 P_0 + 2(1 - t)t P_1 + t^2 P_2, \quad t \in [0, 1]$$

Quadratic Bézier — occluded cap reconstruction



รูปที่ 2.1 เส้นโค้งเบซิเอร์กำลังสองที่ใช้สร้างปลายข้อไข่ที่ถูกบังขึ้นใหม่ จากจุดควบคุม P_0, P_1, P_2 (จัดทำโดยคณะผู้วิจัย)

2.4 การเรียนรู้เชิงลึกและการตรวจจับวัตถุ

โครงข่ายประสาทเทียมแบบคอนโวลูชัน (**Convolutional Neural Network, CNN**) เป็นสถาปัตยกรรมหลัก ของงานวิทัศน์สมัยใหม่ สำหรับงานตรวจจับวัตถุ (object detection) ที่ต้องระบุทั้งตำแหน่งและชนิดของ วัตถุพร้อมกัน ตระกูล **YOLO (You Only Look Once)** ที่เสนอโดย Redmon และคณะ (2016) [5] เป็น วิธีที่ได้รับความนิยมสูงเนื่องจากประมวลผลทั้งภาพในครั้งเดียว (single-stage) ทำให้ทำงานแบบเวลาจริง ได้ YOLO แบ่งภาพเป็นกริดและทำนายกรอบขอบเขต (bounding box) พร้อมความน่าจะเป็นของคลาส โดยตรงจากแต่ละเซลล์

รุ่นล่าสุดในตระกูลนี้ที่โครงการเลือกใช้คือ **YOLOv8** โดย Ultralytics (2023) [6] ซึ่งปรับสถาปัตยกรรม เป็นแบบ *anchor-free* และใช้ decoupled head แบ่งการทำนายตำแหน่งและคลาสออกจากกัน ทำให้จัดการ วัตถุขนาดเล็กและซ้อนทับได้ดีขึ้น สถาปัตยกรรมประกอบด้วย 3 ส่วนคือ backbone (สกัดคุณลักษณะ), neck (รวมคุณลักษณะหลายสเกลด้วย PANet) และ head (ทำนายผล)

ในบริบทการตรวจจับการกีดกร่อน มีงานวิจัยจำนวนมากประยุกต์ใช้ CNN/YOLO อย่างได้ผล เช่น Corrosion-YOLOv5s สำหรับจำแนกการกีดกร่อนของโลหะ [11], การแบ่งส่วนการกีดกร่อนของเหล็กแบบ เวลาจริงด้วยโมเดล semantic/instance segmentation [10], การประเมินการกีดกร่อนบนเสาส่งไฟฟ้าด้วย ภาพจากอากาศยานไร้คนขับ (UAV) ร่วมกับ DCNN [22] และบทปริทัศน์ที่รวบรวมเทคนิคและความ ท้าทายของการเรียนรู้เชิงลึกในงานประเมินการกีดกร่อน [9], [12] งานเหล่านี้ให้ผลลัพธ์เชิงคุณภาพ (ตำแหน่ง/ระดับการกีดกร่อน) เป็นหลัก ซึ่งสอดคล้องกับผลของแนวทางแรกในโครงการนี้ (หัวข้อ 3.3)

2.5 แบบจำลองพื้นฐานสำหรับการแบ่งส่วนภาพ (Segmentation Foundation Models)

จุดเปลี่ยนสำคัญของงานแบ่งส่วนภาพเกิดขึ้นในปี 2023 เมื่อ Meta AI เผยแพร่ **Segment Anything Model (SAM)** [3] ซึ่งเป็นแบบจำลองพื้นฐาน (foundation model) ที่ฝึกบนชุดข้อมูล SA-1B (ภาพ 11 ล้านภาพ พร้อมมาสก์ 1.1 พันล้านมา

สก็) ทำให้สามารถแบ่งส่วนวัตถุที่ไม่เคยเห็นมาก่อนได้แบบ zero-shot ด้วย พรอมต์ (จุด/กรอบ) จุดเด่นคือคุณภาพมาสก์สูงและครอบคลุมวัตถุหลากหลายโดยไม่ต้องฝึกเฉพาะงาน

อย่างไรก็ตาม SAM มีต้นทุนการคำนวณสูงเนื่องจากใช้ image encoder แบบ Vision Transformer ขนาดใหญ่ ไม่เหมาะกับการทำงานแบบเวลาจริงบนอุปกรณ์ขอบ **FastSAM** โดย Zhao และคณะ (2023) [4] จึงเสนอ แนวทางที่ใช้ CNN (บนพื้นฐานของ YOLOv8-seg) ฝึกบนข้อมูลเพียง 2% ของ SAM เดิม แต่ให้ผลลัพธ์ใกล้เคียงและเร็วกว่าถึงราว 50 เท่า เหมาะสำหรับการแบ่งส่วนแบบเวลาจริง โครงการนี้เลือกใช้ FastSAM เป็นตัวแบ่งส่วนหลักบน NVIDIA Jetson และมี SAM เป็นทางเลือกสำรองสำหรับกรณีที่ต้องการคุณภาพสูงสุด

2.6 การวัดขนาดเชิงมิติด้วยภาพ (Vision-based Dimensional Metrology)

การวัดขนาดด้วยเครื่องจักรวิทัศน์ (machine vision metrology) เป็นสาขาที่พัฒนาแล้วสำหรับงาน อุตสาหกรรม โดยความแม่นยำขึ้นกับสามปัจจัยหลัก ได้แก่ (ก) การสอบเทียบกล้อง (camera calibration), (ข) เทคนิคการตรวจหาขอบระดับย่อยพิกเซล (sub-pixel edge detection) และ (ค) คุณภาพของระบบ ถ่ายภาพ [16], [17] ระบบที่มีความละเอียดเชิงพื้นที่ 0.05 มม./พิกเซล สามารถทำความเข้าใจของขอบ ในระดับ 0.005–0.01 มม. ได้ (ดีขึ้น 5–10 เท่าของระยะพิกเซล) หากการสอบเทียบแม่นยำและภาพคมชัด

งานวัดเส้นผ่านศูนย์กลางเชิงอุตสาหกรรมด้วยการนับพิกเซลระดับย่อย [16] และการวัดชิ้นส่วนกลไก ด้วยกล้องเดี่ยว (monocular) แบบคัมค่า [17] แสดงว่าการวัดเชิงมิติจากภาพให้ความแม่นยำสูงพอสำหรับ งานตรวจสอบได้ ประเด็นสำคัญคือ **การแปลงหน่วยพิกเซลเป็นหน่วยกายภาพ (px_per_mm) ต้องอาศัย การสอบเทียบด้วยวัตถุอ้างอิงที่ทราบขนาด** ซึ่งเป็นข้อจำกัดที่หลีกเลี่ยงไม่ได้และสะท้อนในการอภิปราย ผลของโครงการ (หัวข้อ 4.7)

ตัวตรวจจับขอบระดับพิกเซลที่ใช้กันแพร่หลาย ได้แก่ Sobel, Roberts และ Canny โดยแต่ละตัวมีความ แตกต่างด้านความไวต่อสัญญาณรบกวนและความคมของขอบ [16] ในโครงการนี้ ขอบถูกสกัดจากมาสก์ ไบนารีที่ได้จากการแบ่งส่วน (แถวแรก/แถวสุดท้ายของพิกเซลขาวในแต่ละคอลัมน์) จึงลดปัญหาสัญญาณ รบกวนของขอบระดับเทาลงได้ในตัว


2.7 เรขาคณิตหลายมุมมอง พารัลแลกซ์ และการปรับเชิงทนทาน

การถ่ายภาพวัตถุสามมิติด้วยกล้องเดี่ยวเป็นการฉายภาพแบบเพอร์สเปกทีฟ (perspective projection) ทฤษฎีพื้นฐานอยู่ในตำรามาตรฐาน *Multiple View Geometry in Computer Vision* ของ Hartley และ Zisserman [8] ประเด็นที่เกี่ยวข้องกับโครงการมี 2 ประการ

(ก) พารัลแลกซ์ (parallax): เมื่อวัตถุสองชิ้นอยู่คนละระนาบความลึก (เช่น ลวดแนวนอนกับข้อโซ่ แนวตั้งที่ห่างกันตามแกน z ประมาณหนึ่งความหนาของลวด) กล้องที่ทำมุมเอียงจะเห็นตำแหน่งซ้อนทับของ สองชิ้น "เลื่อน" ไปเป็นฟังก์ชันของตำแหน่งในเฟรม การเคลื่อนนี้ทำให้ค่าการสีกกรอบที่วัดต่อข้อต่อ ไล่ระดับเป็นเชิงเส้นจากซ้ายไปขวา ซึ่งต้องชดเชย (หัวข้อ 3.5.6)

(ข) การปรับแบบจำลองเชิงทนทาน (robust fitting): การประมาณเส้นตรง/แบบจำลองจากข้อมูลที่มีค่า ผิดปกติ (outliers) เช่น ขอบมาสก์ที่ขรุขระ ใช้อัลกอริทึม **RANSAC (RANdom Sample Consensus)** ของ Fischler และ Bolles (1981) [7] ซึ่งสุ่มเลือกชุดข้อมูลจำนวนน้อยที่สุดที่กำหนดแบบจำลองได้ (2 จุด สำหรับเส้นตรง) แล้ววัดคุณภาพจากจำนวนจุดที่สอดคล้อง (inliers) ทำซ้ำและเลือกแบบจำลองที่ดีที่สุด โครงการใช้ RANSAC ในการปรับเส้นขอบตรงของลวดแนวนอน (หัวข้อ 3.5.5) เพื่อไม่ให้ปลายโค้งของลวด รบกวนการประมาณความหนา

RANSAC robust line fit — used for wire straight edges



รูปที่ 2.2 RANSAC [7] ปรับเส้นตรงจากจุดที่สอดคล้อง (inliers) โดยไม่ถูกค่าผิดปกติ (outliers) ดึงเบน ต่างจากวิธีกำลังสองน้อยสุดที่ใช้ทุกจุด — ใช้กับการปรับขอบตรงของลวดแนวนอน (จัดทำโดยคณะผู้วิจัย)

2.8 การประมวลผลบนอุปกรณ์ขอบ (Edge Computing)

การนำแบบจำลองการเรียนรู้เชิงลึกไปใช้จริงในภาคสนามต้องอาศัยการประมวลผลที่ตัวอุปกรณ์ (edge) เพื่อลดความหน่วงและการพึ่งพาการเชื่อมต่อเครือข่าย แพลตฟอร์ม **NVIDIA Jetson** [21] เป็นชุด ประมวลผลขอบที่มี GPU เร่งความเร็วและชุดซอฟต์แวร์ JetPack (CUDA, TensorRT, cuDNN) รองรับ งานวิทัศน์และการอนุมานเชิงลึกแบบเวลาจริงในสภาพแวดล้อมอุตสาหกรรมที่มีข้อจำกัดด้านพลังงานและ ความร้อน โครงการเลือก Jetson (สถาปัตยกรรม Ampere, 2048-core GPU) เป็นแกนประมวลผลของต้นแบบ และส่งออกแบบจำลอง FastSAM เป็นรูปแบบ TensorRT engine เพื่อเร่งความเร็ว (ไฟล์ [FastSAM-s.engine](#) ในรีโพสิทอรี)

2.9 สรุปงานวิจัยที่เกี่ยวข้องและช่องว่างที่โครงการเติมเต็ม

กลุ่มงาน	ตัวอย่างอ้างอิง	ผลลัพธ์	ช่องว่าง
ตรวจจับการกัดกร่อนด้วย DL	[9], [10], [11], [12], [22]	เชิงคุณภาพ (ตำแหน่ง/ระดับ)	ไม่ให้ % การสึกกร่อนเชิงมิติ
NDT ลวดสลิง (MFL)	[13], [14], [15]	ตรวจลวดขาด/สูญเสียหน้าตัด	ต้องสัมผัส, ไม่วัดมิติข้อไข
แบ่งส่วนภาพ foundation	[3], [4]	มาส์กคุณภาพสูง zero-shot	เป็นเครื่องมือ ไม่ใช่ตัววัด
วัดขนาดด้วยภาพ	[16], [17]	แม่นยำระดับย่อยพิกเซล	ยังไม่ประยุกต์กับข้อที่บิดงันเอง


กลุ่มงาน	ตัวอย่างอ้างอิง	ผลลัพธ์	ช่องว่าง
โครงการนี้	—	% การสีกกร่อนเชิงเรขาคณิต จากภาพเดี่ยว	เชื่อมช่องว่าง DL↔มิติ↔IACS

สรุป: โครงการนี้เชื่อมช่องว่างระหว่างการแบ่งส่วนภาพด้วย foundation model กับการวัดเชิงมิติที่ สอดคล้องกับมาตรฐาน IACS โดยเสนอกระบวนการสร้างแบบจำลองเรขาคณิตของข้อโซ่/ลวดขึ้นใหม่จาก มาสก์ แล้ววัดการสีกกร่อนจากอัตราส่วน พื้นที่ซ่อนทับ

บทที่ 3 วิธีการดำเนินงานวิจัย

3.1 ภาพรวมระบบ


ระบบประกอบด้วยสามส่วนหลัก (1) ชุดยึดจับโซ่และระบบเก็บภาพ (ฮาร์ดแวร์) (2) โมดูลตรวจจับการ กัดกร่อนด้วย YOLOv8 (แนวทางเสริมเชิงคุณภาพ) และ (3) กระบวนการวัดการสีกกร่อนเชิงเรขาคณิต 8 ขั้นตอน (ผลลัพธ์หลักเชิงปริมาณ) ดังแสดงในรูปที่ 3.1 กระบวนการทั้งหมดพัฒนาด้วยภาษา Python บนไลบรารี OpenCV, NumPy และ Ultralytics และออกแบบให้ทำงานบน NVIDIA Jetson



รูปที่ 3.1 แผนผังกระบวนการวัดการสีกกร่อน 8 ขั้นตอน ตั้งแต่ภาพนำเข้าจนถึงการซ่อนภาพสร้างใหม่ (จัดทำโดยคณะผู้วิจัย)

3.2 ชุดยึดจับโซ่และระบบเก็บภาพ (Hardware)

ได้ออกแบบและสร้างชุดยึดจับโซ่จากอลูมิเนียมโปรไฟล์ โดยใช้โซ่ขนาด 10×25 มม. เป็นตัวอย่างหลัก สามารถยึดจับและขับเคลื่อนโซ่ที่ละข้อเพื่อเข้าสู่กระบวนการตรวจสอบ และรองรับการติดตั้งชุดกล้อง รับภาพและระบบประมวลผล NVIDIA Jetson (สถาปัตยกรรม Ampere, 2048-core GPU) [21] การเก็บภาพ ออกแบบให้ทำงานแบบ synchronize capture รองรับการทำงานต่อเนื่องบนสแตนด์อโลน [8] รูปที่ 3.2 แสดง ตัวอย่างภาพโซ่ที่เก็บได้ซึ่งใช้เป็นภาพนำเข้าของกระบวนการ



รูปที่ 3.2 ตัวอย่างภาพนำเข้า *chain* (สภาพใหม่/อ้างอิง) — ข้อโซ่แนวตั้งถูกลวดแนวนอนสองข้อ คล้องทับที่ตำแหน่ง สัมผัส (interlock) ทั้งสองด้าน

3.3 แนวทางเริ่มต้น: การตรวจจับการกัดกร่อนด้วย Deep Learning (YOLOv8)

หมายเหตุ: แนวทางนี้คือ "แนวทางเริ่มต้น (initial approach)" ของโครงการที่ต่อมาถูก **ลดบทบาท ลงเป็นผลงานเสริม** และปรับไปสู่การวัดเชิงเรขาคณิต (หัวข้อ 3.4) รายงานฉบับปิดโครงการนี้ยังคง บันทึกรายละเอียดของแนวทางแรกไว้อย่างครบถ้วน เนื่องจากเป็นงานที่ได้ดำเนินการจริง (เก็บข้อมูล เทรน โมเดล ทดสอบบนภาพจริง) และเหตุผลของการปรับแนวทาง (pivot) ถือเป็นข้อค้นพบเชิงระเบียบวิธีที่สำคัญ ของโครงการ รายละเอียดในหัวข้อนี้อ้างอิงจากรายงานความก้าวหน้ารอบ 6 เดือน (ส่วนที่ 2)

3.3.1 การเลือกอัลกอริทึมและสภาพแวดล้อมการฝึก

ในระยะแรกได้เลือกใช้ **YOLOv8** [6] เป็นอัลกอริทึมหลักสำหรับตรวจจับการกัดกร่อน โดยอาศัยแนวคิด การตรวจจับวัตถุแบบขั้นตอนเดียว (single-stage/one-stage) ของตระกูล YOLO [5] ซึ่งให้ความเร็วสูง เหมาะกับการทำงานแบบเวลาจริง บนอุปกรณ์ขอบ (NVIDIA Jetson) [21] การฝึกโมเดลดำเนินการบน **Google Colab** เพื่อใช้ทรัพยากร GPU ในการทดลองหาแบบจำลองที่มีประสิทธิภาพ ก่อนนำไปปรับใช้บน Jetson จริง จากร่องรอยของการฝึก (มีทั้ง **box_loss**, **seg_loss**, **cls_loss**, **dfl_loss** และผลลัพธ์เป็น มาสก์ระบายบริเวณกัดกร่อน) โมเดลที่ใช้เป็นชนิด **instance segmentation (YOLOv8-seg)** ซึ่งให้ทั้ง กรอบขอบเขตและมาสก์ระดับพิกเซลของบริเวณกัดกร่อน

3.3.2 ชุดข้อมูลและปัญหา domain gap ที่ต้นทาง

ชุดข้อมูลที่ใช้คือชุด **"Corrosion"** จาก **Roboflow** จำนวน **118 ภาพ** ประเด็นสำคัญที่พบคือ ภาพ ในชุดข้อมูลส่วนใหญ่เป็น **ภาพสังเคราะห์ที่สร้างด้วย generative AI** (สังเกตจากชื่อไฟล์รูปแบบ **Firefly-Inpaint-***, **Firefly-one-realistic-simple-*** ซึ่งบ่งชี้ว่าใช้เครื่องมือ inpainting ของ Adobe Firefly) โดยเป็นภาพการกัดกร่อนบน **ชิ้นส่วนกลไก** เช่น เฟือง แบร้ง จานโลหะ ไม่ใช่ภาพข้อโซ่สมจริง ข้อเท็จจริงนี้อธิบายสาเหตุของ **domain gap** ได้ชัดเจนตั้งแต่ต้นทาง กล่าวคือ ลักษณะพื้นผิว รูปทรง แสง และบริบทของภาพฝึก (ชิ้นส่วนกลไกสังเคราะห์) แตกต่างจากภาพเป้าหมาย

(โซ่สมอจริงที่ผิวหยาบ มีน้ำ/ คราบ และมมมองเฉพาะ) ปัญหาคุณภาพและความเป็นตัวแทนของชุดข้อมูลฝึกนี้สอดคล้องกับข้อสังเกตใน วรรณกรรมว่าคุณภาพชุดข้อมูลมีผลอย่างมากต่อสมรรถนะของการตรวจจับการกัดกร่อน [10], [12]

3.3.3 ผลการฝึกโมเดล

ทำการฝึกจำนวน **150 epochs** ผลการฝึกสรุปได้ดังตารางที่ 3.1 และรูปที่ 3.3


ตารางที่ 3.1 ผลการฝึกโมเดล YOLOv8-seg ตรวจจับการกัดกร่อน (จากรายงานความก้าวหน้ารอบ 6 เดือน)

Model	Precision	Recall	mAP@50
Corrosion YOLOv8	70.7%	58.7%	63.9%

พฤติกรรมการลู่เข้าของการฝึก (รูปที่ 3.3):

- ค่าความสูญเสียฝึก (train losses) ลดลงและลู่เข้าอย่างมีเสถียรภาพทุกตัว โดย **train/box_loss** ลดลงจาก 1.8 → ต่ำกว่า 0.6 แสดงว่าโมเดลเรียนรู้การระบุตำแหน่งวัตถุได้ดี ส่วน **seg_loss, cls_loss, dfl_loss** ลดลงในทำนองเดียวกัน
- ค่าความสูญเสียฝึก validation **val/box_loss** ลดลงจาก 3.5 → ต่ำกว่า 1.5 (มีจุดพุ่งสูงช่วงต้น แล้วลดลงเข้าสู่ระดับต่ำ) เป็นสัญญาณของการเรียนรู้ที่มีเสถียรภาพ
- เมตริกสมรรถนะ **precision, recall, mAP@50, mAP@50-95** ไต่ขึ้นและอึดตัวที่ค่าปลายทาง P = 70.7%, R = 58.7%, mAP@50 = 63.9% ตามลำดับ

YOLOv8-seg corrosion training — Corrosion dataset (118 imgs, 150 epochs) P=70.7% R=58.7% mAP@50=63.9%



รูปที่ 3.3 แผนเส้นโค้งการฝึก YOLOv8-seg บนชุดข้อมูล Corrosion — ค่าความสูญเสีย (box/seg/cls/dfl) ลดลงลู่เข้า และเมตริก precision/recall/mAP ไต่ขึ้นสู่ค่าปลายทาง (สร้างขึ้นใหม่จากค่าที่บันทึกในการฝึกจริง ให้ตรงกับรูปที่ 2.3 ของรายงานความก้าวหน้ารอบ 6 เดือน; จัดทำโดยคณะผู้วิจัย)

3.3.4 ผลการทดสอบเชิงคุณภาพบนภาพโซ่จริง

เมื่อนำโมเดลที่ฝึกแล้วไปทดสอบ (inference) กับ ภาพข้อโซ่จริงที่มีสนิม โมเดลสามารถระบุและระบาย มาสกับบริเวณกัดกร่อนได้ (มาสก์สีเขียวทับบริเวณสนิม) พร้อมค่าความมั่นใจ (confidence) ในช่วงประมาณ 0.5–0.6 ต่อกลองตรวจจับ (อ้างอิงรูปที่ 2.5 ของรายงานความก้าวหน้ารอบ 6 เดือน: ภาพนำเข้า → มาสก์แบ่งส่วน → กลองพร้อมค่าความมั่นใจ) ผลนี้ยืนยันว่าโมเดล ตรวจจับได้จริงเชิงคุณภาพ แต่ค่าความ มั่นใจระดับปานกลางและ Recall 58.7% สะท้อน domain gap ที่วิเคราะห์ไว้ในหัวข้อ 3.3.2

3.3.5 ข้อจำกัดของแนวทางเชิงคุณภาพ

ข้อจำกัดที่พบ ซึ่งนำไปสู่การปรับแนวทาง (หัวข้อ 3.4):

- **ให้ผลเชิงคุณภาพ ไม่ใช่เชิงมิติ** — ผลลัพธ์เป็นการระบุตำแหน่ง/масกับบริเวณกัดกร่อน (มี/ไม่มี) ไม่ได้ให้ปริมาณการสึกกร่อนเป็นเปอร์เซ็นต์ ที่นำไปเทียบกับเกณฑ์ IACS 12% ได้โดยตรง สอดคล้องกับ ข้อสังเกตใน บทปริทัศน์งานตรวจจับการกัดกร่อนด้วย DL ส่วนใหญ่ให้ผลเชิงคุณภาพ [9], [12]
- **domain gap จากชุดข้อมูลสังเคราะห์** — ชุดข้อมูล Corrosion เป็นภาพสังเคราะห์ของชิ้นส่วนกลไก ไม่ตรงกับลักษณะพื้นผิว/แสง/มุมมองของโซสมอจริง ทำให้ค่า Recall ค่อนข้างต่ำ (58.7%) [10]
- **สนิม ≠ การสึกเชิงมิติ** — "สนิม/การกัดกร่อนที่ผิว" (surface corrosion) กับ "การสึกหรอที่ทำให้ขนาด ลดลง (dimensional wear)" เป็นคนละปรากฏการณ์ทางวิศวกรรม เกณฑ์ความปลอดภัยของ IACS อ้างอิงกับ *ขนาดที่หาย* ใ/ไม่ใพื้นที่สนิม [1], [2] ดังนั้นแม้ตรวจจับสนิมได้แม่นยำก็ยังไม่ตอบโจทย์ go/no-go ตาม มาตรฐาน

3.4 การปรับแนวทางสู่การวิเคราะห์เชิงกายภาพ (Pivot to Physical-based Analysis)

จากข้อจำกัดข้างต้น คณะผู้วิจัยตัดสินใจปรับจุดเน้นของผลลัพธ์หลักของโครงการไปสู่ **การวัดการสึกกร่อนเชิงเรขาคณิต/กายภาพ (physical, geometry-based wear measurement)** เนื่องจาก

1. **สอดคล้องกับมาตรฐานโดยตรง** — ให้ค่าการสึกกร่อนเป็นเปอร์เซ็นต์ ที่เทียบกับเกณฑ์ IACS ($\leq 12\%$) และ แนวคิด $\bar{D} \geq 0.88D_0$ ได้ทันที [1], [2]
2. **เชิงปริมาณและทวนสอบได้** — วัดจากรูปทรงจริงของข้อโซ ให้ผลซ้ำได้ (repeatable) และตรวจสอบ ย้อนกลับ กับเวอร์เนียร์คาลิปเปอร์ได้ [16], [17]
3. **ไม่พึ่งชุดข้อมูล annotation ขนาดใหญ่** — ใช้การแบ่งส่วน (segmentation) ด้วย foundation model [3], [4] ร่วมกับแบบจำลองเชิงเรขาคณิต จึงหลีกเลี่ยงปัญหา domain gap ของชุดข้อมูลสนิม


การตรวจจับการกัดกร่อนด้วย YOLOv8 (หัวข้อ 3.3) จึงถูกจัดเป็น **ผลงานเสริม/องค์ประกอบเชิงคุณภาพ** ในขณะที่ระเบียบวิธีในหัวข้อ 3.5 เป็นผลลัพธ์หลักเชิงปริมาณของโครงการ

3.5 ระเบียบวิธีวัดการสึกกร่อนเชิงเรขาคณิต (Geometry-based Wear Pipeline)

หลักการ: ที่ข้อต่อของโซ่ (interlock) หน้าตัดของ **ลวดแนวนอน (horizontal wire)** จะกดสัมผัสเข้าไปใน **ข้อโซ่แนวตั้ง (vertical link)** เมื่อเกิดการสึกกร่อน เนื้อโลหะบริเวณผิวสัมผัสจะหายไป ทำให้พื้นที่ **ซ้อนทับ** ของสองชิ้นส่วนเปลี่ยนไป ระบบจึงนิยามการสึกกร่อนจาก **อัตราส่วนพื้นที่ซ้อนทับ** (รูปที่ 3.4)

$$\text{Wear} = \frac{\text{area}(A \cap B)}{\text{area}(A)} \times 100\%$$

เมื่อ A คือพื้นที่เสี้ยว (crescent) ปลายข้อโซ่แนวตั้งที่สร้างขึ้นใหม่ และ B คือวงกลมปลายลวดแนวนอน ($\emptyset$ = ความหนา ลวด b)



รูปที่ 3.4 นิยามเชิงเรขาคณิตของการสึกกร่อน: พื้นที่เสี้ยว A ของปลายข้อโซ่แนวตั้ง ซ้อนทับกับวงกลม B ของปลายลวดแนวนอน อัตราส่วน $A \cap B / A$ คือค่าการสึกกร่อน (จัดทำโดยคณะผู้วิจัย)

กระบวนการประกอบด้วย 8 ขั้นตอน (แต่ละขั้นบันทึกภาพประกอบรายงานไว้ใน [debug_v2/](#)) ดังตารางที่ 3.2


ตารางที่ 3.2 ขั้นตอนของกระบวนการวัดการสึกกร่อน

ขั้น	กระบวนการ	ผลลัพธ์	โฟลเดอร์ภาพ	อ้างอิง ทฤษฎี
1	Segmentation (FastSAM/SAM)	มาสก์โซ่รวม / ลวดแนวนอน / ข้อแนวตั้ง	01_segmentation	[3], [4]
2	V-correction	แก้เอียงแนวตั้งให้ $d_{top} \approx d_{bot}$	02_v_correction	[8]
3	H-correction	แก้เพอร์สเปกทีฟแนวนอน	03_h_correction	[8]
4	12-point vertical link model	จุดควบคุม 12 จุด + พื้นที่ A	04_vertical_link_model	[18], [20]
5	Wire model	วงกลม B + พื้นที่ B	05_wire_model	[7]
6	Wear = $A \cap B / A$	เปอร์เซ็นต์การสึกกร่อนต่อข้อต่อ	06_wear_overlay	[20]

ชั้น	กระบวนการ	ผลลัพธ์	โฟลเดอร์ภาพ	อ้างอิง ทฤษฎี
7	Reconstruction overlay	ภาพซ้อนการสร้างใหม่บน ภาพจริง	07_recon_overlay	—
8	Full reconstruction mask	มาสก์การสร้างใหม่ทั้งหมด	08_full_recon_mask	—


3.5.1 ชั้นที่ 1 — การแบ่งส่วนภาพ (Segmentation)

ใช้ **FastSAM** [4] (สำรองด้วย SAM [3]) แบ่งภาพโซ่ออกเป็นสามมาสก์ ได้แก่ มาสก์โซ่รวม (full), มาสก์ลวดแนวนอน (wire) และมาสก์ข้อโซ่แนวตั้ง (vertical) การใช้ foundation model ทำให้ได้มาสก์ คุณภาพสูงโดยไม่ต้องฝึกเฉพาะงาน และหลีกเลี่ยงปัญหา domain gap ของชุดข้อมูลสนิม รูปที่ 3.5 แสดง มาสก์การแบ่งส่วนสามชั้น




รูปที่ 3.5(ก) มาสก์โซ่รวม (full) ของตัวอย่าง *chain*

1. Segmentation – horizontal wire mask [chain]



รูปที่ 3.5(ข) มาสก์ลวดแนวนอน (wire) — ใช้สร้างวงกลม B

1. Segmentation – vertical link mask [chain]



รูปที่ 3.5(ค) มาสก์ข้อไขแนวตั้ง (vertical) — ใช้สร้างพื้นที่ A; สังเกตว่าปลายข้อทั้งสองถูกลวดบดบัง เหลือเพียงแถบราง (rail) บนและล่าง

3.5.2 ชั้นที่ 2-3 — การแก้เพอร์สเปกทีฟ (V/H correction)

เนื่องจากภาพถ่ายเป็นการฉายแบบเพอร์สเปกทีฟ [8] ข้อโซ่อาจปรากฏเอียงและความกว้างลอดไม่สม่ำเสมอ ชั้น **V-correction** แก้การเอียงแนวตั้งให้ความหมายอดข้อบนและล่างใกล้เคียงกัน ($d_{top} \approx d_{bot}$) และชั้น **H-correction** แก้เพอร์สเปกทีฟแนวนอนให้ความกว้างลอดสม่ำเสมอ ทั้งสองชั้นเป็นการเตรียม ภาพให้แบบจำลองเรขาคณิตในชั้นถัดไปมีสมมติฐาน (แกนปลายข้อในแนวนอน) ที่ถูกต้อง รูปที่ 3.6 แสดง ผลหลังการแก้

2. V-correction (tilt) theta=23.3deg [chain]



รูปที่ 3.6(ก) ผลการแก้เพอร์สเปกทีฟแนวตั้ง (V-correction) ของ *chain*

3. H-correction b_diff=0.6px (0.3%) [chain]



รูปที่ 3.6(ข) ผลการแก้เพอร์สเปกทีฟแนวนอน (H-correction) ของ *chain*

3.5.3 ขั้นที่ 4 — แบบจำลองข้อโซ่แนวตั้ง 12 จุด (พื้นที่ A)

ข้อโซ่แนวตั้งเป็นวงปิดรูปสเทเดียม (rounded rectangle) ที่ **ปลายโค้งทั้งสองถูกลวดแนวนอนบดบัง** การแบ่งส่วนจึงเหลือเพียงแถบราง (rail) บนและล่าง เราต้อง **สร้างปลายที่ถูกบดบังขึ้นใหม่** เป็นเส้นขอบ สองเส้น (ขอบใน = ขอบรู, ขอบนอก = ขอบข้อ) ซึ่งเนื้อระหว่างสองเส้นคือ **พื้นที่สีขาว A**


แบบจำลองใช้ **จุดควบคุม 12 จุด** ตามภาพอ้างอิงที่ทำ annotation ไว้ (รูปที่ 3.7) ดังนี้ [18], [20]

จุด	ความหมาย	สี
9, 10, 11, 12	ความหนาของข้อ d (บนนอก/บนใน/ล่างใน/ล่างนอก)	แดง
3, 4, 5, 6	มุมปลาย ด้านใน (ขอบรู) — ข้ายบน/ล่าง, ขวบน/ล่าง	เขียว
1, 2, 7, 8	มุมปลาย ด้านนอก — ข้ายบน/ล่าง, ขวบน/ล่าง	เหลือง

ขั้นตอนย่อย (โมดูล `src/link_model.py`):

- แยกข้อ (blob pairing):** ทำไบนารี (>127) ตัดปลายองค์ประกอบเชื่อมต่อ ตัดขึ้นที่มีพื้นที่ < 2000 px แบ่งเป็นกลุ่มบน/ล่างด้วยค่ามัธยฐานของ centroid-y
- สแกนขอบ:** สำหรับแต่ละคอสมันน์ บันทึกพิกเซลขาวแรก/สุดท้ายเพื่อสร้างขอบสี่เส้น t_{out} , t_{in} , b_{in} , b_{out}
- ยอดข้อและความหนา d (จุด 9–12):** หายอด (จุดกึ่งกลางแนวนอนของวงรี) แล้ววัด $d = (d_{top} + d_{bot})/2$ ที่ยอด (ตำแหน่งไม่สีก ใช้เป็นค่าอ้างอิง)
- มุมด้านใน (จุด 3–6):** หาคอสมันน์ที่วาง "เต็มความหนา" (90% ของค่าสูงสุด) เป็นจุดที่รูข้อเปิด แล้วสุมขอบในของทั้งสองรางที่คอสมันน์เดียวกันต่อด้าน (จุดบน–ล่างเรียงตรงกัน)

5. **มุมด้านนอก (จุด 1,2,7,8):** เป็น จุดตัด ของข้อแนวตั้งกับลวดแนวนอน (ไม่ใช่ระยะออฟเซตคงที่) โดย x จากขอบนอกสุดของข้อ และ y จากขอบแถบลวด (จากมาสก์ลวด)
6. **สร้างส่วนโค้ง (เบซิเยร์):** สร้างปลายโค้งด้านในและด้านนอกเป็นเส้นโค้งเบซิเยร์กำลังสองระหว่าง มุมสองจุด โดยมี sagitta ตื้น ($0.35 \times$ คอร์ด) [ทฤษฎีเบซิเยร์ในหัวข้อ 2.3]
7. **พื้นที่ A:** สร้างรูปหลายเหลี่ยมปิด `outer_arc ++ reverse(inner_arc)` แล้วคำนวณพื้นที่ด้วยสูตร Shoelace [20]



รูปที่ 3.7 จุดควบคุม 12 จุดและพื้นที่เสี้ยว A ที่สร้างขึ้นใหม่ของตัวอย่าง *chain* (รายละเอียดวิธีการใน docs/vertical_Link_12point_method.md)


3.5.4 ขั้นที่ 5 — แบบจำลองลวดแนวนอน วงกลม B (พื้นที่ B)

ลวดแนวนอนปรากฏเป็นรูปสเตเดียม (ขอบตรงสองด้าน + ปลายโค้งสองด้าน) เราสร้างปลายโค้งขึ้นใหม่เป็น **วงกลม B** เส้นผ่านศูนย์กลางเท่ากับความหนา b สัมผัสที่ปลาย ซึ่งเป็นหน้าตัดมุมมองด้านบนของ ลวด ณ จุดสัมผัส (โมดูล src/wire_model.py)

ขั้นตอนย่อย:

1. **เลือกลวดหลัก:** ทำไบนารี ดิต پایของค์ประกอบ เลือกชิ้นใหญ่สุดที่ขอบซ้ายไม่ติดเฟรม ($x_1 > 15$ px)
2. **ขอบตรง (RANSAC):** ปรับเส้นขอบบน/ล่างด้วย RANSAC [7] โดยใช้เฉพาะคอสัมผัสตรงกลาง 60% เพื่อไม่ให้ปลายโค้งรบกวนการปรับเส้น
3. **ความหนา b :** ระยะตั้งฉากระหว่างสองเส้นขอบที่คอสัมผัสกลาง (มีตัวประกอบ $\cos(\arctan(\cdot))$ ขดเขยการเอียง)
4. **ปลายลวด (จุด 1):** คอสัมผัสสุดซ้าย; ปฏิเสธปลายที่ติดเฟรม (frame-cut)
5. **มุมสัมผัส (จุด 2):** ตรวจจุดที่ขอบเบนออกจากเส้นตรงด้วยตัวตรวจแบบ persistence (ต้องเบน ต่อเนื่อง 5 คอสัมผัส เกณฑ์ 6 px) เพื่อกันสัญญาณรบกวน
6. **วงกลม B และพื้นที่ B:** วงกลมรัศมี $r = b/2$ สัมผัสในที่ปลาย พื้นที่ $B = \pi r^2$


5. Wire model – circle B + area B [chain]



รูปที่ 3.8 แบบจำลองลวดแนวนอนและวงกลม B ที่สร้างขึ้นใหม่ของตัวอย่าง *chain* (รายละเอียดวิธีการใน docs/horizontal_wire_method.md)

3.5.5 ขั้นที่ 6 — การวัดการสึกกร่อน ($\text{Wear} = A \cap B / A$)

นำพื้นที่เส้น A (ขั้น 4) มาหาส่วนซ้อนทับกับวงกลม B (ขั้น 5) ด้วยการตัดกันของรูปหลายเหลี่ยม (polygon intersection) แล้วคำนวณอัตราส่วน $\text{area}(A \cap B) / \text{area}(A)$ ต่อข้อต่อ พื้นที่ทั้งหมด คำนวณด้วยสูตร Shoelace [20] รูปที่ 3.9 แสดงภาพซ้อนผลการวัดต่อข้อต่อ



รูปที่ 3.9 ภาพซ้อนการสีกกรอนต่อข้อต่อของ *chain* — แต่ละข้อต่อรายงานค่า raw และค่าที่แก้พารัลแลกซ์

3.5.6 การชดเชยพารัลแลกซ์ (Parallax Normalization)


เนื่องจากลวดกับข้อโซ่อยู่คนละระนาบความลึก (ห่างกันประมาณหนึ่งความหนาของลวดตามแนวแกน z) กล้อง ที่ทำมุมเอียงจะเห็นตำแหน่งซ้อนทับ "เลื่อน" เป็นเชิงเส้นจากซ้ายไปขวาของเฟรม [8] ทำให้ค่าการ สีกกรอนต่อข้อต่อไ้ระดับผิดพลาด ระบบจึงประมาณความชัน

$$\text{wear}(x) = w_0 + k(x - x_c)$$

จากข้อต่อทั้งหมดในเฟรม แล้วอ้างอิงกลับสู่กึ่งกลางเฟรม (x_c , ตำแหน่งที่พารัลแลกซ์ ≈ 0) เพื่อให้แต่ละ ภาพให้ค่าการสีกกรอนเดียวที่เสถียร ผลของการชดเชยแสดงในหัวข้อ 4.5

3.5.7 ขั้นที่ 7–8 — การซ้อนภาพและมาสก์การสร้างใหม่

ขั้นสุดท้ายซ้อนแบบจำลองที่สร้างใหม่ (พื้นที่ A, วงกลม B, ส่วนซ้อนทับ) กลับลงบนภาพจริง (รูปที่ 3.10) และสร้างมาสก์การสร้างใหม่ทั้งหมด เพื่อการตรวจสอบด้วยตา (visual verification) และการทวนสอบ



รูปที่ 3.10 ภาพซ้อนการสร้างใหม่ (reconstruction overlay) ของ *chain* — ยืนยันว่าจุดควบคุมและ รูปทรงที่สร้างขึ้นตรงกับขอบจริงของข้อโซ่และลวด


บทที่ 4 ผลการทดลองและการอภิปราย

4.1 ชุดตัวอย่างทดสอบ

ทดสอบกับตัวอย่างโซ่ 3 ชุด ครอบคลุมสามระดับการสีกกร่อน โดยมีค่าอ้างอิงจากการวัดด้วย เวอร์เนียร์คาลิเปอร์ (ground truth) ได้แก่ *chain* (สภาพใหม่/อ้างอิง), *chain3* (~30%) และ *chain4* (~50%) ภาพนำเข้าทั้งสามแสดงในรูปที่ 4.1



รูปที่ 4.1(ก) ตัวอย่าง *chain3* (สีกร่อน ~30%)




รูปที่ 4.1(ข) ตัวอย่าง *chain4* (สีกร่อน ~50%) — สังเกตว่าลวดด้านขวาถูกตัดขอบเฟรม ทำให้วัดได้เพียง 2 ข้อต่อ

4.2 ผลการตรวจจับการกัดกร่อน (YOLOv8)

โมเดล YOLOv8 ให้ค่า $mAP@50 = 63.9\%$ (Precision 70.7%, Recall 58.7%) ตามตารางที่ 3.1 และ รูปที่ 3.3 ผลนี้จัดเป็นผลเชิงคุณภาพที่ใช้คัดกรองบริเวณกัณฑ์กรอนได้ แต่ไม่ให้เกิดการสีกกรอนเชิงมิติ ตามที่อภิปรายในหัวข้อ 3.3 ค่า Recall ที่ค่อนข้างต่ำสะท้อนปัญหา domain gap ของชุดข้อมูลสาธารณะ ซึ่งสอดคล้องกับข้อสังเกตในวรรณกรรมว่าคุณภาพชุดข้อมูลฝึกมีผลอย่างมากต่อสมรรถนะ [10], [12]


4.3 ผลการแบ่งส่วนภาพและการสร้างแบบจำลองต่อเนื่องกัน

การแบ่งส่วนด้วย FastSAM ให้มาส์กสามชั้นคุณภาพดีสำหรับทั้งสามตัวอย่าง (รูปที่ 3.5) การสร้างแบบจำลองข้อโซ่แนวตั้ง 12 จุดและวงกลมลด B ทำงานได้กับตำแหน่งข้อ ขนาด และสภาพการสีกที่แตกต่างกัน โดยจุดควบคุมทั้ง 12 อยู่บนขอบจริง (ตรวจสอบด้วยภาพซ้อนในรูปที่ 3.10) ผลการสร้างแบบจำลองสำหรับ ตัวอย่างที่สีก (chain3, chain4) แสดงในรูปที่ 4.2 และ 4.3




รูปที่ 4.2(ก) แบบจำลองข้อโซ่แนวตั้ง 12 จุดของ chain3

5. Wire model – circle B + area B [chain3]




รูปที่ 4.2(ข) แบบจำลองวงกลม B ของ chain3

4. Vertical link model – 12 points + area A [chain4]




รูปที่ 4.3(ก) แบบจำลองข้อโซ่แนวตั้ง 12 จุดของ chain4 (สีกรมท่า)



รูปที่ 4.3(ข) แบบจำลองวงกลม B ของ chain4 — ลวดด้านขวาถูกตัดเฟรม ระบบจึงวัดแบบข้างเดียว (one-sided) อย่างเหมาะสม

เสถียรภาพของค่าอ้างอิง (gauge stability): ความหนาข้อแนวดิ่ง d และความหนา ลวด b ที่วัดได้ อยู่ในช่วงแคบทั้งสามตัวอย่าง สอดคล้องกับการที่ตัวอย่างมาจากเกจโซ่/ลวดเดียวกัน (รูปที่ 4.4) ยืนยันว่าการวัดค่าอ้างอิงมีความสม่ำเสมอ



รูปที่ 4.4 ความหนาอ้างอิง d (ข้อแนวดิ่ง) และ b (ลวด) ของทั้งสามตัวอย่าง อยู่ในช่วงแคบ (d : 200–211 px, b : 210–222 px) (จัดทำโดยคณะผู้วิจัย)

4.4 ผลการวัดการสึกกร่อน


ผลการวัดการสึกกร่อนต่อตัวอย่าง (ค่า raw รายข้อต่อ และค่าที่แก้พารัลแลกซ์แล้ว) สรุปในตารางที่ 4.1

ตารางที่ 4.1 ผลการวัดการสึกกร่อน

ตัวอย่าง	d (px)	b (px)	จำนวนข้อต่อ	Wear (raw)	Wear (แก้พารัลแลกซ์)	Ground truth (คาลิปเปอร์)
chain	211.0	221.8	3	12.9–23.2%	18.8%	~ใหม่/อ้างอิง
chain3	208.0	218.9	3	21.2–26.7%	24.3%	~30%
chain4	200.0	210.0	2 (ลวดถูกตัดขอบเฟรม)	29.1–32.7%	31.9%	~50%


ผลสำคัญ:

- ลำดับการสึกกร่อนถูกต้องตรงตามกายภาพ: **chain** < **chain3** < **chain4** สอดคล้องกับ ค่าคาลิปเปอร์ (ใหม่ < 30% < 50%) — ระบบจัดลำดับสภาพโซ่ได้ถูกต้อง
- ค่าที่ได้ผ่านการซ้อนภาพยืนยัน (รูปที่ 4.5) ว่าบริเวณซ้อนทับ $A \cap B$ ตรงกับผิวสัมผัสที่สึกจริง




รูปที่ 4.5(ก) ภาพซ้อนการสึกกร่อนของ **chain3**

6. Wear overlay A n B / A [chain4]

รูปที่ 4.5(ข) ภาพซ้อนการสึกกร่อนของ *chain4*

4.5 ผลของการชดเชยพารัลแลกซ์

การชดเชยพารัลแลกซ์ได้ผลชัดเจน โดยลดการกระจายของค่าภายในเฟรมเดียวจาก ~10 จุดเปอร์เซ็นต์ เหลือ ~1.5 จุดเปอร์เซ็นต์ ทำให้แต่ละภาพให้ค่าเดียวที่เสถียร (เช่น *chain4* ได้ 31.9% ทั้งสองข้อต่อ) รูปที่ 4.6 เปรียบเทียบค่า raw รายข้อต่อ (เส้นประ) กับค่าที่แก้แล้ว (เส้นทึบ) จะเห็นว่าค่า raw ไล่ระดับ ตามตำแหน่ง x ขณะที่ค่าที่แก้แล้วราบเรียบรอบค่ากึ่งกลางเฟรม




รูปที่ 4.6 ค่าการสึกกร่อนรายข้อต่อก่อน (เส้นประ) และหลัง (เส้นทึบ) การชดเชยพารัลแลกซ์ ความชันซ้าย→ขวาของค่า raw ถูกกำจัด (จัดทำโดยคณะผู้วิจัย)

ตัวอย่าง	ความชันพารัลแลกซ์ (%/1000px)	การกระจาย raw	การกระจายหลังแก้
chain	+7.75	~10.3 จด%	~1.4 จด%
chain3	+3.88	~5.5 จด%	~1.7 จด%
chain4	+5.88	~3.6 จด%	~0.0 จด%

4.6 การเปรียบเทียบกับค่าจริงและการวิเคราะห์ความคลาดเคลื่อน

รูปที่ 4.7 เปรียบเทียบค่าที่วัดได้ (แก้พารัลแลกซ์) กับค่าคาลิปเปอร์ พร้อมเส้นเกณฑ์ IACS 12% จะเห็นว่าค่าที่วัดได้ต่ำกว่าค่าจริงอย่างเป็นระบบ (24.3% เทียบ 30%, 31.9% เทียบ 50%) แต่รักษา ลำดับและทิศทางการเพิ่มขึ้นได้ถูกต้อง สาเหตุเชิงหลักการอภิปรายในหัวข้อ 4.7



รูปที่ 4.7 ค่าการสึกกร่อนที่วัดได้ (แก้พารัลแลกซ์) เทียบกับค่าคาลิเปอร์ พร้อมเส้นเกณฑ์ IACS 12% (จัดทำโดยคณะผู้วิจัย)

4.7 การอภิปรายผลและข้อจำกัด

- ทิศทาง/ลำดับถูกต้อง แต่สเกลสัมบูรณ์ยังต่ำกว่าค่าจริง** — ค่าที่วัดได้ (24.3%, 31.9%) ต่ำกว่า ค่าคาลิเปอร์ (30%, 50%) อย่างเป็นระบบ สาเหตุเชิงหลักการคือ พื้นที่ A และวงกลม B ถูกสร้างขึ้นจาก **ขนาดอ้างอิงที่ยังไม่ล็อก** (ความหนาของข้อ d และความหนาของกึ่งกลาง b) แล้วจัดวางตามขอบที่มองเห็น อัตราส่วนซ้อนทับจึงสะท้อน "ระยะกดล็อกของการประกบ" มากกว่า "ปริมาณเนื้อโลหะที่หายไป" ซึ่งเป็นนิยามการสึกกร่อนที่แท้จริง เนื้อที่หายไปบางส่วนถูกลดที่พาด ผ่านบดบัง (occlusion) และถูกตัวแบ่งส่วนปรับให้เรียบ ทำให้สัญญาณการสึกที่ระดับสูงถูกบีบอัด
- การเทียบให้ตรงค่าคาลิเปอร์ต้องมีมาตรฐานอ้างอิง** — การแปลงค่าที่วัดได้ให้ตรง 30/50 พอดี จากตัวอย่างเพียง 2 ชุด มีสถานะทางคณิตศาสตร์เท่ากับ "การสอบเทียบ (calibration) 2 จุด" ซึ่งเป็นสิ่งที่หลีกเลี่ยงไม่ได้สำหรับทุกวิธี (แม้แต่แบบจำลองกายภาพที่สมบูรณ์ก็ต้องทราบค่า "50% ของอะไร") [16], [17] การให้ระบบรายงานเป็นเปอร์เซ็นต์สัมบูรณ์ที่แม่นยำจึงต้องมีชุดโซ่ มาตรฐาน (reference standards) อย่างน้อย 2 ระดับการสึกที่ทราบค่าแน่นอน
- ข้อจำกัดของมุมมองและการบดบัง** — การถ่ายภาพมุมเดียว (monocular) ทำให้ผิวสัมผัสที่สึกจริงถูกบดบัง การต่อยอดสู่ระบบสเตอริโอ/หลายมุมมอง [8] จะช่วยเปิดเผยพื้นผิวสึกได้ดีขึ้น
- ข้อจำกัดของภาพขอบเฟรม** — **chain4** มีลวดถูกตัดขอบเฟรม ทำให้วัดได้เพียง 2 ข้อต่อและวัด b แบบข้างเดียว ระบบจัดการกรณีนี้ได้อย่างเหมาะสม (graceful degradation) แต่ควรออกแบบระยะ ถ่ายภาพให้เห็นข้อต่อครบในงานจริง

4.8 การเชื่อมโยงกับมาตรฐาน IACS

ระบบให้ค่าความหนาอ้างอิง d (ข้อแนวตั้ง) และ b (ลวดแนวนอน) ที่ตำแหน่งไม่ล็อก ซึ่งสอดคล้องกับ แนวคิด D_0 ของ IACS โดยตรง [1], [2] และให้เปอร์เซ็นต์การสึกกร่อนต่อข้อต่อที่นำไปเทียบกับเกณฑ์ $\leq 12\%$ ได้ ในเชิงหลักการ ระบบสามารถขยายให้รายงานในรูปอัตราส่วนเส้นผ่านศูนย์กลาง $\bar{D}/D_0$ เพื่อให้ตรงนิยาม IACS ได้ในงานระยะต่อไป จากรูปที่ 4.7 จะ

เห็นว่าเมื่อสอบเทียบสเกลแล้ว ทั้ง **chain3** และ **chain4** อยู่เหนือเส้นเกณฑ์ 12% อย่างชัดเจน กล่าวคือระบบสามารถตัดสิน go/no-go ได้ถูกต้องในเชิงลำดับ

บทที่ 5 สรุปผล ข้อเสนอแนะ และแผนระยะต่อไป

5.1 สรุปผลการดำเนินงานตามวัตถุประสงค์

ตารางที่ 5.1 สรุปผลตามวัตถุประสงค์

วัตถุประสงค์	ผลที่ได้	สถานะ
1. ตรวจจับการกัดกร่อน (DL)	โมเดล YOLOv8 (mAP@50 = 63.9%) เป็นผลเชิงคุณภาพ	สำเร็จบางส่วน (pivot)
2. วัดการสึกกร่อน (CV)	Pipeline วัดเชิงเรขาคณิต 8 ขั้น + ขดเชยพาร์ลแลกซ์ ให้ลำดับถูกต้องตรงกายภาพ	สำเร็จ (ผลลัพธ์หลัก)
3. ลดคน/เวลาตรวจสอบ	ระบบอัตโนมัติต้นแบบบน Jetson	สำเร็จเชิงต้นแบบ
4. เผยแพร่ผลงาน	อยู่ระหว่างเตรียมต้นฉบับ	กำลังดำเนินการ
5. บูรณาการ AI กับพาณิชย์	ต้นแบบใช้งานจริงบนบก	สำเร็จเชิงต้นแบบ

5.2 สรุปองค์ความรู้และผลงานเด่น

โครงการนี้พัฒนากระบวนการวัดการสึกกร่อนของโซ่เชิงปริมาณจากภาพเดี่ยว ที่ (ก) ผสาน foundation model (FastSAM) [4] กับแบบจำลองเรขาคณิตที่สร้างปลายข้อ/ลวดที่ถูกบดบังขึ้นใหม่ (ข) นิยามการ สึกกร่อนจากอัตราส่วนพื้นที่ซ้อนทับ $A \cap B / A$ ที่ทวนสอบได้ และ (ค) ขดเชยพาร์ลแลกซ์เพื่อให้ค่าต่อ ภาพเสถียร ผลลัพธ์ให้ลำดับการสึกกร่อนที่ถูกต้องตรงกายภาพและสอดคล้องกับค่าคาลิเปอร์ ซึ่งเป็น ก้าวสำคัญจากการตรวจจับเชิงคุณภาพไปสู่การวัดเชิงปริมาณที่เชื่อมกับมาตรฐาน IACS

5.3 ข้อเสนอแนะและแผนระยะต่อไป

- สร้างชุดข้อมูลมาตรฐาน (reference standards) ที่ทราบค่าการสึกกร่อนแน่นอนหลายระดับ เพื่อสอบเทียบ ให้ค่าที่รายงานตรงกับค่ากายภาพเชิงสัมบูรณ์ และประเมินความไม่แน่นอน (uncertainty) [16], [17]
- พัฒนาเมตริกฐาน "เนื้อโลหะที่หายไป" (material-deficit) — วัดส่วนต่างระหว่างรูปทรงปลายข้อ/ลวด ที่ยังไม่สึก (สร้างใหม่) กับเนื้อโลหะจริงจากมาสก์ โดยเฉพาะที่ปลายลวดซึ่งหันเข้าช่องว่าง (ไม่ถูกบดบัง) เพื่อจับสัญญาณการสึกระดับสูงได้ดีขึ้น
- ต่อยอดสู่ระบบสเตอริโอ/หลายมุมมอง [8] ตามที่ออกแบบฮาร์ดแวร์ไว้ เพื่อลดผลของการบดบังและ พาร์ลแลกซ์
- รายงานผลในรูปอัตราส่วน $\bar{D}/D_0$ ให้ตรงนิยาม IACS [1], [2] และเพิ่มเกณฑ์แจ้งเตือนที่ 12%
- ปรับแต่งการอนุมานบนอุปกรณ์ขอบ โดยส่งออกแบบจำลองเป็น TensorRT engine [21] เพื่อให้ทำงาน แบบ real-time บนสายการตรวจสอบเคลื่อนที่
- ประกอบและทดสอบระบบอิเล็กทรอนิกส์รับภาพ พร้อมพัฒนาซอฟต์แวร์ควบคุมและประมวลผลภาพครบวงจร

เอกสารอ้างอิง (References)

- [1] International Association of Classification Societies (IACS), *Recommendation No. 10 — Anchoring, Mooring and Towing Equipment*, IACS, 2022. [ออนไลน์]. เข้าถึงได้จาก:
<https://ww2.eagle.org/content/dam/eagle/regulatory-news/2022/IACS-Rec-10.pdf>
- [2] International Association of Classification Societies (IACS), *Requirements concerning Mooring, Anchoring and Towing (UR A1 & A2)*, IACS, 2007.
- [3] A. Kirillov, E. Mintun, N. Ravi, et al., "Segment Anything," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 4015–4026. arXiv:2304.02643.
- [4] X. Zhao, W. Ding, Y. An, et al., "Fast Segment Anything," *arXiv preprint arXiv:2306.12156*, 2023.
- [5] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [6] G. Jocher, A. Chaurasia, and J. Qiu, *Ultralytics YOLOv8*, 2023. [ออนไลน์]. เข้าถึงได้จาก:
<https://github.com/ultralytics/ultralytics>
- [7] M. A. Fischler and R. C. Bolles, "Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography," *Communications of the ACM*, vol. 24, no. 6, pp. 381–395, 1981.
- [8] R. Hartley and A. Zisserman, *Multiple View Geometry in Computer Vision*, 2nd ed. Cambridge, U.K.: Cambridge University Press, 2004.
- [9] X. Yao, Y. Wu, G. Xie, D. Zhao, and D.-H. Xia, "A comprehensive survey on multimodal computer vision (CV)-assisted corrosion assessment and corrosion prediction," *Corrosion Reviews / Anti-Corrosion Methods and Materials*, 2026, doi:10.1177/1478422X251387524.
- [10] "Real-time detection of steel corrosion defects using semantic and instance segmentation models based on deep learning," *Journal of Materials Research and Technology (ScienceDirect)*, 2025, doi:10.1016/j.jmrt.2025.05.0562.
- [11] "Intelligent identification of metal corrosion based on Corrosion-YOLOv5s," *Anti-Corrosion Methods and Materials (ScienceDirect)*, 2022, doi:10.1016/j.matchemphys.2022. [ออนไลน์]. เข้าถึงได้จาก:
<https://www.sciencedirect.com/science/article/abs/pii/S0141938222001858>
- [12] "Deep learning in corrosion assessment and control: a critical review of techniques and challenges," *Corrosion Reviews*, De Gruyter, 2024, doi:10.1515/correv-2024-0060.
- [13] "Wire Rope Damage Detection Based on Magnetic Leakage and Visible Light," *Journal of Failure Analysis and Prevention*, Springer, 2023, doi:10.1007/s11668-023-01682-z.
- [14] "Nondestructive Inspection of Steel Cables Based on YOLOv9 with Magnetic Flux Leakage Images," *Journal of Sensor and Actuator Networks (JSAN)*, vol. 14, no. 4, 2025, doi:10.3390/jsan14040080.
- [15] "Wire Rope Defect Recognition Method Based on MFL Signal Analysis and 1D-CNNs," *Sensors (MDPI)*, vol. 23, no. 7, art. 3366, 2023, doi:10.3390/s23073366.
- [16] "Sub-Pixel counting based diameter measurement algorithm for industrial Machine vision," *Measurement (ScienceDirect)*, 2023, doi:10.1016/j.measurement.2023.113842.

- [17] "A Cost-Effective Method for Automatically Measuring Mechanical Parts Using Monocular Machine Vision," *Sensors (MDPI/PMC)*, 2023, PMC10346874.
- [18] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4th ed. New York, NY: Pearson, 2018.
- [19] N. Otsu, "A Threshold Selection Method from Gray-Level Histograms," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979.
- [20] S. Suzuki and K. Abe, "Topological structural analysis of digitized binary images by border following," *Computer Vision, Graphics, and Image Processing*, vol. 30, no. 1, pp. 32–46, 1985.
- [21] NVIDIA Corporation, *NVIDIA Jetson: Edge AI and Robotics Platform*, 2024. [ออนไลน์]. เข้าถึงได้จาก: <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/>
- [22] A. Savino, et al., "Automated corrosion surface quantification in steel transmission towers using UAV photogrammetry and deep convolutional neural networks," *Computer-Aided Civil and Infrastructure Engineering*, 2025, doi:10.1111/mice.13434.

หมายเหตุการอ้างอิง: เลข DOI/URL ของรายการ [9]–[17], [22] อ้างอิงจากฐานข้อมูลวารสาร (ScienceDirect, MDPI, Springer, SAGE, Wiley, De Gruyter) โปรดตรวจสอบเลขหน้า/DOI ที่แน่นอน กับต้นฉบับตีพิมพ์ก่อนส่งเวอร์ชันสุดท้าย

ภาคผนวก ก: ภาพประกอบตามกระบวนการ (per-process figures)

ภาพผลลัพธ์ทุกขั้นตอนสำหรับตัวอย่าง `chain`, `chain3`, `chain4` บันทึกไว้ที่โฟลเดอร์ `debug_v2/` (มีอยู่ในรีโพสิทอรีสำหรับใช้ประกอบรายงาน):


- `debug_v2/00_input/` — ภาพนำเข้า
- `debug_v2/01_segmentation/` — มาสก์แบ่งส่วน (โซ่รวม/ลวด/ข้อแนวตั้ง)
- `debug_v2/02_v_correction/, 03_h_correction/` — ภาพหลังแก้เพอร์สเปกทีฟ
- `debug_v2/04_vertical_link_model/` — จุดควบคุม 12 จุด + พื้นที่ A
- `debug_v2/05_wire_model/` — วงกลม B + พื้นที่ B
- `debug_v2/06_wear_overlay/` — ภาพซ้อนการสึกกร่อน $A \cap B/A$
- `debug_v2/07_recon_overlay/, 08_full_recon_mask/` — ภาพสร้างใหม่
- `debug_v2/09_report/*.txt` — รายงานตัวเลขต่อตัวอย่าง (raw + แก้วาร์ลแลกซ์)

ก.1 ภาพมาสก์การสร้างใหม่ทั้งหมด (full reconstruction mask)

8. Full reconstruction mask [chain]

d=211px b=222px wear L=18.2% R=23.2%

[TRIGGERED] 3 interlock(s) measured




A (link crescent)
 B (wire cap)
 A n B (overlap)

ภาพ ก.1(ก) มาสก์การสร้างใหม่ทั้งหมดของ *chain*

8. Full reconstruction mask [chain3]

d=208px b=219px wear L=25.0% R=26.7%

[TRIGGERED] 3 interlock(s) measured





A (link crescent)
 B (wire cap)
 A n B (overlap)

ภาพ ก.1(ข) มาสก์การสร้างใหม่ทั้งหมดของ *chain3*

8. Full reconstruction mask [chain4]

d=200px b=210px wear L=32.7% R=29.1%

[TRIGGERED] 2 Interlock(s) measured (wire cut - partial view)



A (link crescent)
B (wire cap)
A n B (overlap)


ภาพ ก.1(ค) มาส์กการสร้างใหม่ทั้งหมดของ chain4

ก.2 ภาพซ้อนการสร้างใหม่ (reconstruction overlay) ของตัวอย่างที่สี่

7. Reconstruction overlay (opacity) on real image [chain3]

d=208px b=219px interlocks=3

[TRIGGERED] 3 Interlock(s) measured




ภาพ ก.2(ก) ภาพซ้อนการสร้างใหม่ของ chain3

7. Reconstruction overlay (opacity) on real image [chain4]

d=200px b=210px interlocks=2

[TRIGGERED] 2 Interlock(s) measured (wire cut - partial view)



ภาพ ก.2(ข) ภาพซ้อนการสร้างใหม่ของ chain4

ภาคผนวก ข: รายงานตัวเลขดิบต่อตัวอย่าง (raw pipeline reports)

รายงานตัวเลขดิบจากกระบวนการ (ไฟล์ `debug_v2/09_report/*.txt`) สำหรับการทวนสอบ

```
chain.png : d=211.0px b=221.8px 3 interlocks
  right @x=1571: raw=23.2% corr=18.4% (A=54262 B=38669 AnB=12576)
  left @x= 772: raw=18.2% corr=19.6% (A=48680 B=38669 AnB=8837)
  right @x= 272: raw=12.9% corr=18.2% (A=47812 B=35265 AnB=6178)
  Parallax slope +7.75%/1000px -> WEAR(corrected)=18.8%

chain3.png : d=208.0px b=218.9px 3 interlocks
  left @x= 852: raw=25.0% corr=25.4% (A=52490 B=37297 AnB=13109)
  right @x=1669: raw=26.7% corr=23.9% (A=60311 B=37297 AnB=16074)
  right @x= 322: raw=21.2% corr=23.7% (A=55071 B=36625 AnB=11673)
  Parallax slope +3.88%/1000px -> WEAR(corrected)=24.3%

chain4.png : d=200.0px b=210.0px 2 interlocks (wire cut - partial view)
  left @x=1091: raw=32.7% corr=31.9% (A=50975 B=34621 AnB=16655)
  right @x= 475: raw=29.1% corr=31.9% (A=54220 B=37981 AnB=15754)
  Parallax slope +5.88%/1000px -> WEAR(corrected)=31.9%
```

ภาคผนวก ค: รายละเอียดวิธีการเชิงเทคนิค

รายละเอียดเชิงลึกของแบบจำลองสองส่วนหลักบันทึกไว้ในเอกสารประกอบของรีโพสิทอรี:

- docs/vertical_link_12point_method.md — แบบจำลองข้อโซ่แนวตั้ง 12 จุด (พื้นที่ A) พร้อมการทวนสอบ
- docs/horizontal_wire_method.md — แบบจำลองลวดแนวนอนวงกลม B พร้อมการทวนสอบ

โค้ดหลักของกระบวนการอยู่ที่ `src/link_model.py`, `src/wire_model.py`, `src/wear_overlap.py` และสคริปต์รันกระบวนการทั้งหมดที่ `run_v2.py`

รายงานฉบับสมบูรณ์ — จัดทำเพื่อปิดโครงการวิจัย โปรดตรวจทานตัวเลข ค่าอ้างอิง IACS และ เลข DOI/หน้าของเอกสารอ้างอิง [1]–[22] ให้ตรงกับต้นฉบับก่อนส่งฉบับพิมพ์